RAG Chunking 综合测试文档

用途：专门用于测试 RAG 文档解析、结构识别、Chunk Size、Overlap、Delimiter、标题层级、列表以及表格保护策略。请把它当作实验数据，而不是普通阅读材料。

建议测试顺序

第一轮：固定长度切块。第二轮：加入换行/段落 delimiter。第三轮：加入标题层级。第四轮：观察简单表格是否被切开。第五轮：测试长表格。第六轮：调整 chunk size，观察正文、表格和标题在不同参数下的变化。

测试时建议记录：chunk_size、overlap、delimiter、每个 chunk 的 token 数、chunk 是否跨越标题、chunk 是否截断表格、chunk 是否包含完整表头。

1. 普通连续文本

城市租住服务平台通常需要同时处理房源信息、用户咨询、订单状态以及租住政策等多类数据。这些数据来源不同，文本长度差异明显，而且同一个业务问题可能分散在多个段落中。因此在构建检索增强生成系统时，不能简单地把整份文档作为一个向量，也不能完全依赖固定字符数进行切割。更合理的做法通常是先尽可能恢复原始文档的结构，再根据自然段落、标题层级、列表和表格等结构进行分块，最后再结合块大小和重叠区域控制最终的检索单元。对于连续正文，切块的核心目标是尽量保持上下文完整，同时避免单个块过大导致召回结果过于粗糙。这个段落专门用于测试在没有特殊结构的情况下，纯正文经过 chunk_size 和 overlap 之后会产生什么样的边界。

2. 很短的段落

这是一个非常短的段落。

第二个短段落。

这里故意只保留一句话。

每个段落之间都有明确换行。

最后再放一个短句，用于测试相邻小块是否会被合并。

3. 超长段落

这是一个故意构造的超长段落，用来测试当单个自然段本身已经超过目标 chunk size 时，Chunker 到底采取什么策略。真实知识库中经常会出现这种情况，例如制度说明、合同条款、产品介绍、技术规范或者一整段业务规则可能没有明显换行，但内容本身非常长。如果 Chunker 只依赖换行作为 delimiter，那么它可能只能把整个段落视为一个整体；如果系统强制要求每个 chunk 不能超过固定 token 数，又必须在段落内部寻找更细的切分边界。这个段落因此被设计成明显长于普通测试块的长度，并且尽量保持连续语义。对于这个段落，请分别使用很小、中等和较大的 chunk size 进行测试，记录系统是在段落边界结束、按照 token 数强制拆分，还是允许生成超过目标长度的

chunk。还可以额外观察 overlap 是否会在超长段落内部真正发挥作用，以及切分后第二个 chunk 是否保留前一个 chunk 的结尾上下文。为了让测试更加明显，继续增加内容：如果一个系统既要保证检索精度，又要保证生成阶段有足够上下文，通常不能只追求块越小越好。块过小会让一个完整规则被拆散，块过大又会降低检索的针对性。因此，chunk size 实际上是召回精度、上下文完整性和向量检索效率之间的一个工程折中。本段故意不插入额外的标题和表格，目的是单独观察纯连续文本在不同切块策略下的表现。

4. 标题 + 正文

4.1 房源审核

房源发布后，需要经过基础信息校验、地址校验和图片检查。审核通过后，房源状态才会从草稿或待审核变更为可出租。

4.2 订单创建

订单创建前应确认房源仍然可租，并检查同一房源是否已经存在有效订单。创建订单以后，支付和异步任务可以按照既定状态流转。

5. 多级标题

5.1 文档解析

5.1.1 PDF 解析

PDF 解析需要尽量恢复标题、正文、图片和表格等结构。

5.1.2 Word 解析

Word 文档通常包含明确的段落和标题样式，可以利用这些信息恢复层级。

5.2 文档切块

5.2.1 普通文本

普通文本可以优先按自然段进行切分，再结合目标块大小进行合并。

5.2.2 表格

表格需要尽可能作为结构化元素保护，避免普通文本切分逻辑直接进入表格内部。

5.3 检索

检索阶段需要关注召回数量、相关性和排序策略。

6. 列表

下面是故意设计的无序列表：

- 检查文档是否解析成功。

- 统计文档中的标题和段落数量。
- 识别表格、图片和公式等特殊结构。
- 按照 chunk size 和 overlap 生成初始 chunks。
- 检查 chunk 是否出现结构截断。

下面是故意设计的有序列表：

1. 第一步：解析原始文件。
2. 第二步：建立结构化中间表示。
3. 第三步：执行切块。
4. 第四步：生成 embedding。

7. 简单表格

下面是一张较小的表格，用于观察最基础的 table 结构能否被完整保留。

员工类型	入职年限	年假天数
正式员工	满1年	5天
正式员工	满5年	10天
正式员工	满10年	15天

8. 很长的表格

下面的表格刻意设计得比较长。请重点测试：当 chunk_size
较小时，系统是否会把表头、数据行以及相邻行切到不同 chunk；同时观察 Parser
是否把表格识别成独立结构，以及 Chunker 是否把 table 当作普通字符串处理。

序号	部门	岗位	级别	最低服务年限	年假	备注
1	研发	Java开发	P1	2年	5天	正常
2	产品	产品经理	P2	3年	7天	正常
3	测试	测试工程师	P3	4年	9天	正常
4	运营	运营专员	P4	5年	11天	需要审批
5	市场	市场专员	P5	6年	13天	正常
6	行政	行政助理	P1	7年	15天	正常
7	财务	财务专员	P2	8年	5天	正常
8	客服	客服专员	P3	9年	7天	需要审批
9	研发	Java开发	P4	10年	9天	正常
10	产品	产品经理	P5	1年	11天	正常
11	测试	测试工程师	P1	2年	13天	正常
12	运营	运营专员	P2	3年	15天	需要审批

序号	部门	岗位	级别	最低服务年限	年假	备注
13	市场	市场专员	P3	4年	5天	正常
14	行政	行政助理	P4	5年	7天	正常
15	财务	财务专员	P5	6年	9天	正常
16	客服	客服专员	P1	7年	11天	需要审批
17	研发	Java开发	P2	8年	13天	正常
18	产品	产品经理	P3	9年	15天	正常
19	测试	测试工程师	P4	10年	5天	正常
20	运营	运营专员	P5	1年	7天	需要审批
21	市场	市场专员	P1	2年	9天	正常
22	行政	行政助理	P2	3年	11天	正常
23	财务	财务专员	P3	4年	13天	正常
24	客服	客服专员	P4	5年	15天	需要审批
25	研发	Java开发	P5	6年	5天	正常
26	产品	产品经理	P1	7年	7天	正常
27	测试	测试工程师	P2	8年	9天	正常
28	运营	运营专员	P3	9年	11天	需要审批
29	市场	市场专员	P4	10年	13天	正常
30	行政	行政助理	P5	1年	15天	正常
31	财务	财务专员	P1	2年	5天	正常
32	客服	客服专员	P2	3年	7天	需要审批
33	研发	Java开发	P3	4年	9天	正常
34	产品	产品经理	P4	5年	11天	正常
35	测试	测试工程师	P5	6年	13天	正常
36	运营	运营专员	P1	7年	15天	需要审批
37	市场	市场专员	P2	8年	5天	正常
38	行政	行政助理	P3	9年	7天	正常
39	财务	财务专员	P4	10年	9天	正常
40	客服	客服专员	P5	1年	11天	需要审批

9. 表格前后都有正文

这一段放在表格之前，用来模拟真实知识库里的业务说明。用户首先看到的是文字规则，紧接着才出现结构化数据。测试时请观察 chunk 是否会因为接近 chunk_size
而在表格进入之前提前截断，以及表格之后的解释文字是否被错误地拼接到上一块。

房型	面积	月租	状态
一室一厅	45㎡	3200元	可租
两室一厅	72㎡	4500元	已租
三室两厅	108㎡	6200元	可租
Loft	58㎡	3900元	可租

上面的数据表描述了几类典型房源。正常情况下，表格中的每一行都属于同一个结构化数据集合，因此切块时应尽量不要把单元格内容拆成互不相关的片段。如果系统需要把一个超长表格拆分成多个 chunk，至少应该保证每个 chunk 都拥有必要的表头或其他能够解释列含义的信息。

10. 单页同时存在正文 + 表格 + 正文

这一节专门模拟 PDF 中非常常见的一页布局：上方是正文，中间是一张表格，下方继续解释表格。目标不是测试表格有多长，而是观察解析结果是否能维持页面中的先后顺序，以及 Chunker
是否会把表格错误地拼接到不相关的段落中。请在不同 chunk_size 下重复测试。

指标	值	说明
召回数量	20	初始候选
重排数量	5	进入最终上下文
Overlap	10%	保留前后文

表格之后继续保留正文。这里故意让表格前后的内容语义相关但结构不同，从而观察系统是否保留了正确的顺序信息。如果解析器输出了 paragraph、table、paragraph 三种 Block，那么理想情况下 Chunker
应该知道表格是一个独立结构，而不是仅仅看到三段字符串。

测试完成后的记录建议

- 记录最小 chunk size 下表格第一次出现在哪个 chunk。
- 记录表头有没有随着数据行一起保留。
- 记录 overlap 是否进入表格内部。
- 记录超长表格是被整体保留、被分片，还是被普通文本逻辑截断。
- 记录标题与正文是否被拆开，以及是否能利用标题层级恢复上下文。

这份 PDF 的目的不是模拟某一种具体业务，而是让你故意把 Chunker 的边界条件暴露出来。